

ODIR

RECONOCIMIENTO DE ENFERMEDADES OCULARES POR MEDIO DE IMÁGENES

WILSON HOYOS BENAVIDES | IA para Ccias. e Ingenierías | 12 de noviembre de 2022

OBJETIVO

Se desea realizar un modelo de clasificación de enfermedades oculares basado en una base de datos de libre acceso en línea que cuenta con fotografías de fondo de retina etiquetadas según el parte médico correspondiente a la presencia de enfermedades deducibles del ojo.

INTRODUCCIÓN

Durante varios años se ha venido aplicando la inteligencia artificial para el reconocimiento de objetos y patrones y material audiovisual, los *software* capaces de reconocer rostros con los que ya estamos familiarizados en teléfonos y computadoras datan de casi 40 años, y desde entonces, la existencia y popularidad del código abierto sumado al desarrollo de tecnologías e información ha permitido escalar estas aplicaciones a diversos campos significando desarrollo de impacto en áreas como la médica que será de interés para el presente proyecto. Reconocer, además de ser un palíndromo definido por el DRAE como establecer la identidad de algo o alguien, es una acción recurrente en los proyectos de Inteligencia Artificial dada la capacidad de las máquinas para aprender y encontrar patrones en modelos de aprendizaje supervisados o no que agiliza, facilita y resuelve tareas que restarían mayor esfuerzo y tiempo al ser humano.

Ocular es un adjetivo relacionado al ojo, para el caso concreto del proyecto actual, se refiere al ojo humano, ese órgano esférico de morfología y fisiología tan perfecta que nos relaciona con el mundo externo y gracias al cual podemos dar detalle de nuestra percepción física de los objetos que existen y que (en sus límites naturales) podemos observar, esta proeza solo puede ser lograda gracias a su anatomía que transforma estímulos visuales en forma de luz provenientes del exterior en señales eléctricas interpretadas por el cerebro como figuras que percibimos de manera interna. Esta conexión nerviosa se da de forma directa a la región occipital del cerebro ubicada en la zona baja posterior de nuestra cabeza y debido a esta comunicación tan directa, el ojo humano ha sido desde hace muchos años estudiado para analizar de forma no invasiva el estado del cerebro entre otros órganos relacionados a este (que realmente son casi todos), si bien, cada ojo es único y esto le otorga relevancia en la identificación de una persona incluso preferible sobre la huella, existen patrones que se dan en el fondo ocular y alrededor de la iris típicos de algunas patologías.

Recientemente la medicina homeopática o alternativas de salud han tomado importancia incluso en el ámbito científico debido a su (en algunas ocasiones) innegable efectividad para diagnosticar, prevenir y curar enfermedades; entre estas formas de medicina, existe la iridología que se centra en el estudio de la iris y los patrones que se ven de cerca al inspeccionar un ojo humano para diagnosticar el estado de un paciente y progreso de sus enfermedades sean estas renales, hepáticas, neurológicas o cardiorrespiratorias entre muchas otras. Este proyecto pretende proponer un algoritmo que reconozca mencionados patrones y, en conjunto con otras características de

Diagrama anatómico detallado de un ojo humano en sección transversal, mostrando las estructuras internas y externas. Las etiquetas incluyen:

- Ora Serrata
- Conducto de Schlemm
- Músculo Recto superior
- Esclerótica
- Coroides
- Retina
- Nervio Óptico
- Papila Óptica
- Arteria y vena centrales de la Retina
- Músculo Recto Inferior
- Cuerpo Ciliar (Músculo ciliar)
- Cámara Posterior
- Cristalino
- Cámara Anterior
- Córnea
- Iris
- Músculo Recto superior

PÁGINA 2



Figura 2: Conexión del ojo al cerebro

LA BASE DE DATOS:

La base de datos que se consultó se puede encontrar en “Kaggle” con la dirección WEB <https://www.kaggle.com/datasets/andrewmvd/ocular-disease-recognition-odir5k>.

Datos colectados por Shangong Medical Technology Co., Ltd. de distintos hospitales e instituciones de salud en China empleando cámaras fotográficas comerciales de distintas marcas y resoluciones.

Esta consta de 34 columnas incluyendo dos de imágenes (por cada ojo) además de las relacionadas al paciente y su historia clínica (identificación, edad, sexo, diagnóstico profesional por cada ojo) con información de más de 5.000 pacientes distintos con sus respectivos diagnósticos brindados por un profesional en salud, dentro de esta se recogen pacientes en 8 estados: sano, con diabetes, con hipertensión, con cataratas, con glaucoma, con miopía, con degeneración macular relacionada a la edad y otras anomalías. De esta base se usará un 80% de los datos para entrenamiento del software y 20% de pacientes aleatorios para evaluar su desempeño en el que se medirá principalmente sus True Positive Rate (TPR) y False Positive Rate (FPR) al ser categorías cuantitativas que pueden bien estar correctas o erradas únicamente, como estadístico de negocio, se tratará de estimar el tiempo y costos de una IPS de implementar este software en lugar de la atención del profesional en salud partiendo del gasto que representa los métodos de diagnóstico presenciales.

EXPLORACIÓN DESCRIPTIVA DEL DATASET

La información que resume el dataset fue obtenida a partir de funciones realizadas en el anexo “exploración_y_preprocesado.ipynb” Debido a inconformidad con el orden en que se entrega la información, se decidió utilizar formato One Hot Encoding para visualiar de mejor manera los datos y así se obtuvo el siguiente resumen:

	ID	Patient	Age	N	D	G	C	A	H	M	O
count	6392.000000	6392.000000	6392.000000	6392.000000	6392.000000	6392.000000	6392.000000	6392.000000	6392.000000	6392.000000	6392.000000
mean	2271.150814	57.857947	0.328692	0.332134	0.062109	0.062891	0.049906	0.031758	0.047872	0.248436	
std	1417.559018	11.727737	0.469775	0.471016	0.241372	0.242786	0.217768	0.175370	0.213513	0.432139	
min	0.000000	1.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
25%	920.750000	51.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
50%	2419.500000	59.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
75%	3294.000000	66.000000	1.000000	1.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
max	4784.000000	91.000000	1.000000	1.000000	1.000000	1.000000	1.000000	1.000000	1.000000	1.000000	1.000000

De ahí que tenemos 6392 pacientes diferentes con información de cada ojo, una mayor prevalencia de pacientes diabéticos en comparación con las demás variables, seguido de pacientes sanos, con otras enfermedades, cataratas, glaucoma, degeneración macular relacionada a la edad, hipertensión arterial.

Existen casos de pacientes con hasta tres enfermedades al mismo tiempo en uno o los dos ojos, por lo que se separó la información en 3 DataFrames que contienen los pacientes según el número de enfermedades que padecen, esto solo fue útil durante la exploración de los datos.

PACIENTES CON UNA ENFERMEDAD

	ID	N	D	G	C	A	H	M	O	Num of diseases	Disease
0	0	0	0	0	1	0	0	0	0	1	Cataract
1	1	1	0	0	0	0	0	0	0	1	Normal
4	5	0	1	0	0	0	0	0	0	1	Diabetes
7	8	1	0	0	0	0	0	0	0	1	Normal
8	9	0	0	0	0	0	0	0	1	1	Other diseases/abnormalities
...
6386	4683	0	1	0	0	0	0	0	0	1	Diabetes
6387	4686	0	1	0	0	0	0	0	0	1	Diabetes
6388	4688	0	1	0	0	0	0	0	0	1	Diabetes
6389	4689	0	1	0	0	0	0	0	0	1	Diabetes
6390	4690	0	1	0	0	0	0	0	0	1	Diabetes

5391 rows × 11 columns

PACIENTES CON DOS ENFERMEDADES


	ID	N	D	G	C	A	H	M	O	Num of diseases	Disease
2	2	0	1	0	0	0	0	0	1	2	(Diabetes, Other diseases/abnormalities)
3	4	0	1	0	0	0	0	0	1	2	(Diabetes, Other diseases/abnormalities)
5	6	0	1	0	0	0	0	0	1	2	(Diabetes, Other diseases/abnormalities)
6	7	0	1	0	0	0	0	0	1	2	(Diabetes, Other diseases/abnormalities)
10	11	0	1	0	0	0	1	0	0	2	(Diabetes, Hypertension)
...
6276	4551	0	1	0	0	0	0	0	1	2	(Diabetes, Other diseases/abnormalities)
6310	4588	0	1	0	0	0	0	0	1	2	(Diabetes, Other diseases/abnormalities)
6313	4591	0	1	0	0	0	1	0	0	2	(Diabetes, Hypertension)
6372	4659	0	1	0	0	0	0	0	1	2	(Diabetes, Other diseases/abnormalities)
6391	4784	0	0	0	0	1	1	0	0	2	(Age related Macular Degeneration , Hypertensi...
955 rows × 11 columns											

PACIENTES CON TRES ENFERMEDADES


	ID	N	D	G	C	A	H	M	O	Num of diseases	Disease
160	188	0	1	0	1	0	0	0	1	3	(Diabetes, Cataract, Other diseases/abnormalit...
267	305	0	1	0	0	0	1	0	1	3	(Diabetes, Hypertension , Other diseases/abnor...
546	625	0	0	1	1	0	0	0	1	3	(Glaucoma, Cataract, Other diseases/abnormalit...
808	938	0	1	0	0	1	0	1	0	3	(Diabetes, Age related Macular Degeneration , ...
1030	1263	0	0	1	0	0	1	0	1	3	(Glaucoma, Hypertension , Other diseases/abnor...
	ID	N	D	G	C	A	H	M	O	Num of diseases	Disease
4566	2100	0	1	0	1	0	0	0	1	3	(Diabetes, Cataract, Other diseases/abnormalit...
4572	2107	0	1	0	1	0	0	0	1	3	(Diabetes, Cataract, Other diseases/abnormalit...
4630	2168	0	1	0	1	0	0	0	1	3	(Diabetes, Cataract, Other diseases/abnormalit...
4660	2200	0	1	0	1	0	0	0	1	3	(Diabetes, Cataract, Other diseases/abnormalit...
4702	2282	0	1	0	1	0	0	0	1	3	(Diabetes, Cataract, Other diseases/abnormalit...
(46, 11)											

Por indicaciones del trabajo, se crearon datos nulos aleatorios en 2 columnas de forma que se dificultara el trabajo, para ello se eligieron las columnas de sexo y edad que aportan información descriptiva relevante para la predicción.

DISTRIBUCIÓN DE EDADES EN LOS DATOS



DISTRIBUCIÓN DE SEXO EN LOS DATOS



Así mismo se evidenció un ejemplo visual de cada caso de patología donde se observa a grandes rasgos algunas de las diferencias aparentes determinantes en el dictamen médico que deberá distinguir el código.



Figura 3: Normal:



Figura 4: Diabetes




Figura 5: Glaucoma



Figura 6: Cataratas




Figura 7: Degeneración macular relacionada a la edad




Figura 8: Hipertensión arterial



Figura 9: Miopía



Figura 10: Otras enfermedades

ITERACIONES DE DESARROLLO

Inicialmente, el preprocesamiento de los datos consistió en la importación al Notebook, seguida de su descompresión y ubicación en carpetas de forma organizada para facilitar su consulta, posterior a esto, se realizó la exploración documental mediante DataFrames y gráficos resultantes de estos sumados a manipulación básica de datos para moldearlos según los requerimientos del trabajo, además de una normalización fundamentada en la reducción del tamaño de las imágenes a uno estándar.

El desarrollo de modelos preliminares y ensayos sobre la clasificación cualitativa de las imágenes médicas se evidencia en el archivo anexo denominado como “predicción.ipynb” donde se realizó con apoyo de los distintos módulos ofrecidos por tensorflow, keras y sklearn que facilitan y desarrollan la predicción basada en algoritmos supervisados y no supervisados de inteligencia artificial.

Inicialmente, se separaron en DataFrames distintos por enfermedades oculares y se enfrentaron respecto a aquel que contiene información de los pacientes normales




Figura 11: Ejemplos de ojos con cataratas




Figura 12: Ejemplos de ojos sanos

Tomando estos dos grupos, organizados en un solo DataFrame de igual cantidad de datos mezclados aleatoriamente se realizó el primer intento de predicción dividiendo en grupos de entrenamiento, testeo y validación usando redes neuronales iterando en distintas épocas y permutaciones para encontrar el modelo que mejor realiza la tarea de clasificar por enfermedad según fotografía de fondo de retina. Los resultados obtenidos fueron graficados como se muestran a continuación.

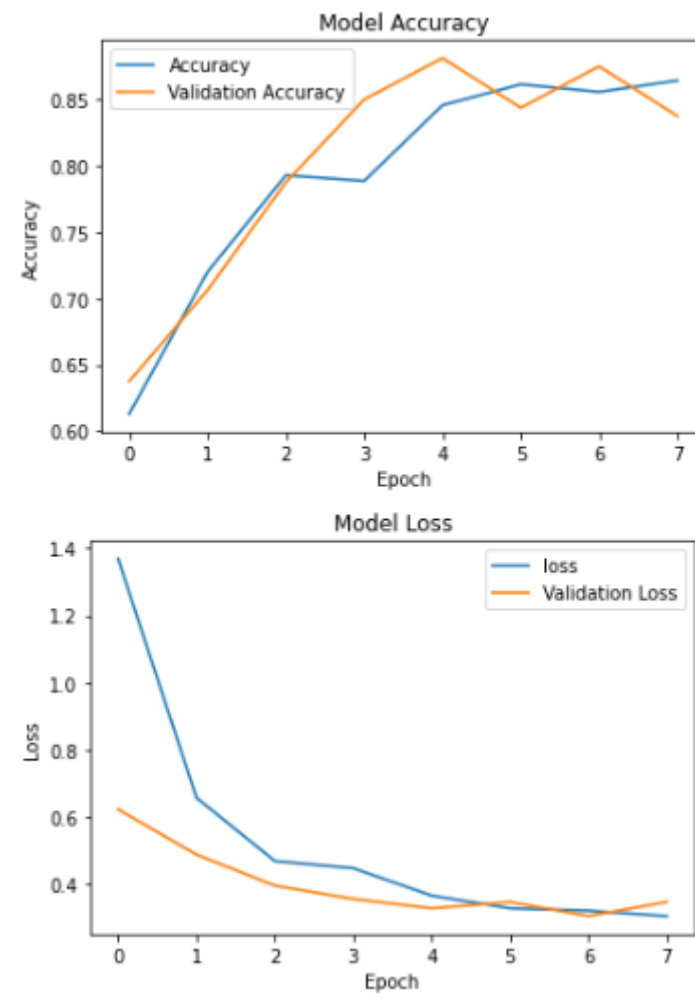


Figura 13: Precisión y función de costo

Se hace que el número de épocas óptimo está cercano a 4 sin sobrecargar nuestro modelo de entrenamiento a costo de gasto computacional y tiempo invertido.

Con un accuracy cercano a 0.87, una función de pérdida de 0.3 se considera un excelente desempeño en la tarea de clasificación entre ojo con cataratas en relación a ojo sano.

RETOS Y CONSIDERACIONES DE DESPLIEGUE

El paso siguiente será realizar la misma operación descrita con las demás patologías siguiendo el prototipo indicado para clasificar cataratas debido a que se observó una alta precisión y los demás modelos son esencialmente iguales al seguido hasta ahora.

En cuanto al despliegue, escalabilidad y reproducibilidad que demanda la sociedad actual de Big Data se debe tener en cuenta un reentrenamiento a medida que aumenta la cantidad de datos disponibles.

CONCLUSIÓN

En modelos como el trabajado en el presente proyecto, pese a tener una cantidad inmensa de datos y clasificaciones posibles, basta con comparar dos de estos y hallar un buen modelo de predicción perfeccionado para escalar, repetir y reproducir con otros datos y otros conjuntos de clasificaciones debido a que el proceso de entrenamiento es bastante similar. Asimismo se comprobó que no solo basta con la información contenida en las imágenes para realizar una predicción acertada, también debe apoyarse de información descriptiva de la población puesto que factores como la edad y el sexo también son influyentes en el desarrollo de las patologías descritas.